

Procesamiento de Lenguaje Natural con Aprendizaje Profundo, Máster en Ciencia y Tecnología Informática

Algunos consejos para escribir tu primer artículo

Objetivos de la sesión

- Comprender la estructura estándar de un paper científico (en PLN)
- Presentar experimentos y resultados correctamente
- Evitar errores frecuentes en papers científicos

¿Qué hace realmente un paper científico?

- Comunica una **contribución científica**
- Plantea y valida **hipótesis**
- **Justifica** decisiones **metodológicas**
- Describe **experimentos reproducibles**
- **Compara** con baselines y trabajos previos
- **Analiza resultados** y limitaciones

¿Qué es una contribución científica?

- Debe aportar conocimiento nuevo o evidencia experimental
- Ejemplo: “Comparamos distintas estrategias de prompting para detectar mensajes de odio.”
-  “Usamos BERT.”

Plantear y validar hipótesis

- La investigación intenta responder preguntas
- ¿La calidad del prompt mejora el rendimiento del sistema?
- “¿Los LLMs son capaces de entender la ironía?

Ejemplos de NO hipótesis

-  “Vamos a probar varios modelos.”
-  “Queremos obtener buenos resultados.”
-  “Aplicaremos prompting.”

Justifica decisiones metodológicas

- No basta con decir qué hicisteis
- Debéis explicar por qué elegisteis: un modelo, prompting o fine-tuning, un dataset...
 - ✓ Elegimos XLM-R porque el dataset es multilingüe.
 - ✓ Balanceo de clases debido al fuerte desbalanceo del dataset.
 - ✓ Truncation a 512 tokens porque la mayoría de textos eran cortos.
 - ✓ Few-shot prompting porque las clases minoritarias tenían pocos ejemplos.

Estructura típica de un paper

- Abstract
- Introduction
- Related Work
- Methodology
- Experimental Setup
- Results and Discussion
- Conclusions

El abstract

- Debe resumir el problema, enfoque y resultados
- Debe incluir resultados cuantitativos
- Se recomienda escribirlo al final

La introducción

- Debe **contextualizar el problema** y justificar su **relevancia**.
- Debe **resumir** los principales **enfoques previos** y sus **limitaciones**.
- Debe presentar la **hipótesis** y las **contribuciones** principales.
 - En papers cortos de conferencias o shared tasks: **1 - 1.5 páginas**.
 - En artículos largos: **2–3 páginas**.

Related Work

- Revisa **trabajos anteriores** relacionados con el problema que aborda el artículo.
- Permite **contextualizar la contribución** de nuestro trabajo.
- De cada trabajo:
 - ¿Qué problema aborda?
 - ¿Qué enfoque utiliza?
 - ¿Qué datasets o recursos emplea?
 - ¿Qué resultados obtiene?

Ejemplo: resumen de un trabajo

cita

¿qué problema?

¿qué recursos?

¿qué enfoques?

¿qué resultados?

Ghosh, Richard Fabbri, and Muresan (2017) exploited the conversation context in sarcasm detection. The authors used the Discussion Forum data (Oraby et al., 2016b), which contains sarcastic responses from a forum and their corresponding context (the original post and its replies). They also collected sarcastic and non-sarcastic tweets to create a dataset for their experiments. Several types of LSTM networks were investigated, showing an F1 of 70.56 % for the Discussion Forum data and an F1 of 73.45 % on the Twitter dataset.

Dataset

- Fuente de los datos
- Idioma y tipo de texto
- Distribución de clases
- Histogramas y estadísticas





Figure 2: Class distribution in training and test datasets (3 classes)




Vemos que el 95% de los textos tienen una longitud menor o igual que 49 tokens. Vamos a seleccionar una tamaño máximo de 50.

Enfoques

- Leer artículos similares.
- Si tu enfoque implica algún tipo de preprocesamiento de los textos, común a todos los enfoques, puedes explicarlo antes.
- Si usas técnicas de oversampling o data augmentation, también puedes explicarlo antes.
- ¿Cómo organizar los enfoques?
 - Enfoques tradicionales de aprendizaje automático
 - Aprendizaje profundo: CNN, BiLSTM
 - Fine-tuning: BERT, etc.
 - Prompting

Ejemplo



To represent the drug reviews based on BERT, the texts were tokenized using the vocabulary of BERT's pre-trained model and the tokenizer provided by `bert-for-tf2`.³ The pre-processed texts resulted in a vocabulary of 30,522 tokens. As a last preprocessing step, based on the cumulative distribution function over the length of reviews (see Fig. 3), we set the length of processed texts to 250 tokens.

Since the output of the BERT model consists of a representation of the texts using contextualized word embeddings, we can add top layers for the classification task. In particular, as can be seen in Fig. 6, we use a bidirectional LSTM layer followed by a fully connected perceptron and softmax layers. We have chosen Bi-LSTM because it is simpler than the hybrid architectures and obtains similar results, as will be seen in Section 4.

Experimental Setup

- train/dev/test splits,
- modelos e hiperparámetros
- random seeds,
- Información sobre GPUs

Resultados y discusión

- Breve descripción de las métricas utilizadas.
 - Tablas con resultados
 - Matrices de confusión
- Comparar modelos
 - Comparar con estado del arte
- Analizar errores
- Discutir limitaciones

Ejemplo

Table 2

Comparison of the methods.

Approach	F1
CRF	0.6487
BiLSTM (Wiki-PubMed-PMC)	0.4326
BiLSTM+CRF (Wiki-PubMed-PMC)	0.5805
BERT	0.6710
BioBERT	0.6954
ClinicalBERT	0.6810

Ejemplo (resultados a nivel de clase)

Table 3

Entity-level results of CRF

Label	Precision	Recall	F1	Support
DISEASE	0.6991	0.4912	0.5770	454
RARE DISEASE	0.8332	0.8164	0.8247	1095
SIGN	0.5313	0.3987	0.4556	958
SYMPTOM	0.7778	0.5185	0.6222	54
Micro-avg	0.7112	0.5963	0.6487	2561
Macro-avg	0.7103	0.5562	0.6199	2561
Macro-weighted	0.6953	0.5963	0.6384	2561

Resultados y discusión

In this paper, we study several methods for recognizing rare diseases and their clinical manifestations. We propose a CRF baseline system using linguistic features. Second, we implement multiple BiLSTMs, testing different classifiers at the output layer such as softmax or CRF, as well as exploring different strategies to initialize their input vectors, such as random initialization and three pre-trained word embedding models, one of them was trained on biomedical texts. Moreover, we explore three implementations of BERT, which differ between them by the type of texts used to pre-train the model. The RareDis corpus is used to train the models and evaluate them. The experiments show that BioBERT obtains the best micro and macro-weighted-average F1, with improvements around 5% over the baseline (CRF) results. BiLSTM does not even outperform the baseline in terms of F1.

Conclusiones y trabajo futuro

- Algunos autores comienzan con un breve resumen del problema y los enfoques utilizados.
- No hay que volver a repetir toda la discusión del apartado anterior!!!
- Es suficiente con explicar la **conclusión principal**: cuál es el **mejor enfoque** y resultado?, supera el estado del arte? se ha **validado la hipótesis**? ¿qué desafíos no se resolvieron?
- **Trabajo futuro**: describe brevemente **posibles líneas de trabajo futuro** (qué otros enfoques podrías utilizar para seguir avanzando en el problema).

Errores frecuentes

- Falta de claridad
- No justificar decisiones metodológicas
 - Falta de rigor experimental y reproducibilidad
- Resultados sin análisis ni discusión.
 - Imágenes ilegibles
 -

Checklist antes de enviar

- ¿Las contribuciones están claras?
- ¿El sistema está claramente explicado?
- ¿Los experimentos son reproducibles?
- ¿Las tablas e imágenes son legibles?

Para terminar

- Un buen paper comunica ciencia
- La claridad es imprescindible
- El objetivo es que otros puedan entender y reproducir vuestro trabajo