

**Procesamiento de Lenguaje Natural con
Aprendizaje Profundo,
Máster en Ciencia y Tecnología Informática
Curso 2025-2026**

Tema 1.2. Tareas básicas PLN

Objetivos

Al finalizar esta presentación, el estudiante será capaz de:

- Comprender por qué el **preprocesamiento del texto** es un paso fundamental en los sistemas de PLN
- Identificar las **principales tareas básicas de PLN**, como la tokenización, la eliminación de stopwords y la lematización
- Conocer el propósito del **análisis sintáctico** y del **análisis semántico** en el procesamiento del lenguaje natural
- Entender cómo estas tareas constituyen la **base de los modelos avanzados de PLN** que se estudiarán en el curso

Índice

- ¿Por qué es necesario el preprocesamiento del texto?
- Tareas básicas de preprocesamiento
 - Tokenización
 - Eliminación de stopwords
 - Stemming y lematización
 - Otras tareas de normalización
- Análisis sintáctico (visión general)
- Análisis semántico (visión general)
- Resumen

¿Por qué preprocesar el texto?

El preprocesamiento es un paso imprescindible en cualquier sistema de PLN.

El preprocesamiento transforma texto crudo en representaciones que los algoritmos pueden utilizar.

El texto en lenguaje natural es **no estructurado** y contiene **ruido y mucha variabilidad lingüística**.

El preprocesamiento permite:

- estructurar el texto,
- reducir variabilidad lingüística,
- facilitar el análisis automático (el texto puede ser utilizado por algoritmos)

Tareas básicas de preprocesamiento

- Tokenización
- Eliminar stop words (palabras de parada)
- Stemming y Lematización.
- Otras tareas de preprocesamiento

Tokenización

- Dividir un texto en **unidades básicas** llamadas *tokens* (palabras, números, signos de puntuación).

Ejemplo: *El niño come manzanas.*

→ ["El", "niño", "come", "manzanas", "."]

Por qué es importante

- Define qué es una “palabra” para el sistema.
- Paso previo a todas las tareas posteriores.

Ejercicio sobre Tokenización

- Implementa un código (en Python) que permita tokenizar el siguiente texto:

Hello, how are you? I'm fine :) Email me at a isegura@inf.uc3m.es or visit <https://hulat.inf.uc3m.es/nosotros/miembros/isegura>.

La salida esperada debe ser algo como:

```
["Hello", ",", "how", "are", "you", "?", "I", "'", "m", "fine", ":)", "Email", "me",  
"at", "a", "isegura@inf.uc3m.es", "or", "visit",  
"https://hulat.inf.uc3m.es/nosotros/miembros/isegura", "."]
```

[Solución](#)

Stopwords

- **Palabras más comunes** en un idioma y que **no añaden significado relevante** al texto.
 - Ejemplos de stopwords en inglés: “the”, “is”, “in”, “for”, “where”, “when”, “to”, “at” etc.
 - Ejemplos de stopwords en español: de, que, el, en y, a ,los, se, del, las, un, por, con, no una, etc.
- En un dominio concreto (por ejemplo, el dominio clínico) la lista de stopwords podría ser ampliada con palabras comunes de dicho dominio: paciente, médico, ambulancia, etc.
- Ejercicio

Stopwords

- Al eliminar las stopwords conseguimos:
 - Disminuir el tamaño del vocabulario =>.
 - Disminuir la dimensionalidad en modelos de representación como la bolsa de palabras o tf-idf.
 - Modelos más eficientes
 - Reduce ruido, el algoritmo se puede centrar en las palabras que sí aportan semántica al texto.
- Sin embargo, las stopwords no deben ser eliminadas en otras aplicaciones de PLN como la traducción automática o el reconocimiento de entidades.

Lematización

- Dada una palabra, la lematización consiste en devolver su lema o forma canónica (palabra que aparece en un diccionario).
- Ejemplos:
 - *comió, comiendo, comeré, come -> comer.*
 - *niño, niña, niños, niñas, Niños, Niñas... -> niño*

Lematización

- Ventajas:
 - Reduce ruido y variabilidad lingüística.
 - Disminuye tamaño del vocabulario
 - Disminuye dimensionalidad en modelos de representación como la bolsa de palabras y tf-idf.Modelos más eficientes.
- Muy útil en aplicaciones de PLN como la clasificación de textos o recuperación de información.
- [Ejercicio.](#)

Stemming

- Similar a la lematización, dada una palabra, devuelve su raíz.
- Basada en algoritmos como [Porter](#) o [Lancaster](#).
- Algunos ejemplos de reglas:
 - *S -> . Ejemplo: cats -> cat*
 - *SSES -> SS. Ejemplo: kisses -> kiss*
 - *EED -> EE. Ejemplo. agreed -> agree*
- Stemming es más eficiente que la lematización, pero menos robusta. Ejemplos de errores:
 - *stories -> stori (debería ser story),*
 - *leaves -> leav (debería ser leaf),*
 - *horses -> hors (debería ser horse),*
 - *better -> better (debería ser good).*
- [Ejemplo](#)

Otras tareas de preprocesamiento

- Transformar a minúsculas
- Eliminar signos de puntuación, números, etc (puedes utilizar patrones).

Análisis sintáctico (visión general)

- El análisis sintáctico estudia la **estructura gramatical** de las oraciones. Permite identificar:
 - la función de cada palabra en la frase
 - las relaciones entre palabras
- Incluye tareas como:
 - Etiquetado morfosintáctico (POS tagging)
 - Análisis de dependencias sintácticas
- En este curso no se aborda en profundidad, pero es una tarea fundamental en muchos sistemas de PLN.
- ¿Para qué se utiliza?
 - Análisis de frases complejas
 - Extracción de relaciones entre entidades
 - Apoyo a tareas semánticas posteriores

Análisis semántico (visión general)

- El análisis semántico se centra en el **significado del texto**.
- En el PLN clásico, se basa principalmente en:
 - relaciones léxicas (sinonimia, hiperonimia, antonimia, etc.)
 - recursos lingüísticos como diccionarios y ontologías

Permite abordar tareas como:

- desambiguación del significado de palabras
- análisis del contenido semántico del texto

En temas posteriores se estudiará cómo el significado puede aprenderse automáticamente mediante modelos profundos.

Resumen

- El lenguaje natural es no estructurado y ambiguo, por lo que requiere un procesamiento específico.
- El preprocesamiento transforma el texto crudo en representaciones manejables por los algoritmos
- Las principales tareas básicas de PLN incluyen: Tokenización, Eliminación de stopwords, Stemming y lematización, Otras tareas de normalización (minúsculas, signos, números)
- Más allá del preprocesamiento, el PLN puede analizar:
 - la estructura gramatical del texto (análisis sintáctico)
 - el significado de palabras y expresiones (análisis semántico)
- Estas tareas constituyen la base conceptual sobre la que se construyen los modelos avanzados de PLN estudiados en el curso

Procesamiento de Lenguaje Natural con Aprendizaje Profundo,

Gracias!!!

<https://github.com/isegura/PLN-tema1>