

**Procesamiento de Lenguaje Natural
con Aprendizaje Profundo,**
Máster en Ciencia y Tecnología Informática
Curso 2025-2026

Tema 1.4. Herramientas PLN

Índice

- Introducción: herramientas para Procesamiento del Lenguaje Natural
- Tipos de herramientas de PLN
- NLTK
- spaCy
- Gensim
- fastText
- Comparativa de herramientas de PLN
- Resumen

Objetivos

Al finalizar esta presentación, el estudiante será capaz de:

- Conocer las principales herramientas software utilizadas en Procesamiento del Lenguaje Natural
- Identificar qué tipo de tareas de PLN permite abordar cada herramienta
- Seleccionar la herramienta más adecuada en función de la tarea, los datos y el contexto de aplicación

Introducción

- El lenguaje natural es **complejo, ambiguo y no estructurado**
- Las tareas de PLN requieren:
 - segmentar texto
 - analizar su estructura lingüística
 - extraer información relevante
- Implementar estas tareas **desde cero es costoso y propenso a errores**
- Las herramientas de PLN proporcionan **componentes reutilizables** que facilitan el desarrollo de sistemas basados en texto.
- El desarrollo de sistemas de PLN se apoya en estas **herramientas** que abstraen la complejidad del lenguaje natural

Tipos de herramientas de PLN

Existen distintos tipos de herramientas según el objetivo:

- **Análisis lingüístico:** proporcionan información morfosintáctica y semántica. Basadas en recursos lingüísticos y/o modelos entrenados. Ejemplos: **NLTK**, **spaCy**
- **Herramientas orientadas a pipelines y aplicaciones:** integran el análisis lingüístico en flujos completos de PLN. Priorizan eficiencia y uso práctico. Ejemplo: **spaCy**
- **Herramientas basadas en modelos estadísticos:** aprenden representaciones distribucionales del texto. Ejemplos: **Gensim**, **fastText**
- **Herramientas basadas en modelos preentrenados:** reutilizan modelos entrenados a gran escala. Ejemplo: **Hugging Face**

No hay una herramienta “mejor” en general: la elección depende de la tarea, los datos y el contexto de uso.

NLTK (Natural Language Toolkit)

- Librería clásica de PLN en Python. Muy utilizada en docencia y en investigación introductoria
- Orientada al análisis lingüístico. Sus funcionalidades principales son:
 - Tokenización y segmentación de texto
 - Stemming y lematización
 - Etiquetado morfosintáctico (POS tagging)
 - Parsing sintáctico
 - Acceso a recursos lingüísticos (p. ej., WordNet). Proporciona información semántica (relaciones sinonimia, hiperonimia, antonimia).

Ventajas: Muy didáctica y bien documentada. Ideal para entender los fundamentos del PLN.

Limitaciones: No orientada a producción. Rendimiento limitado. No incluye modelos profundos modernos.

NLTK es una herramienta clave para aprender los fundamentos del PLN, aunque no es la opción habitual en aplicaciones industriales modernas.

spacy

- Librería moderna de PLN en Python, orientada a aplicaciones reales. Muy utilizada en entornos industriales.
- Permite desarrollar pipelines eficientes.
- Multilingüe.
- Sus principales funcionalidades son:
 - Tokenización y segmentación de texto
 - Lematización
 - Etiquetado morfosintáctico (POS tagging)
 - Análisis de dependencias sintácticas
 - Reconocimiento de entidades nombradas (NER)
 - Representación semántica (basada en vectores) para palabras y documentos. Permite calcular similitud semántica entre textos. Útil para tareas como agrupación de textos

Ventajas: Muy eficiente y rápida Pipelines integrados y fáciles de usar.

Limitaciones: Menos orientada a la experimentación lingüística. No es un framework de entrenamiento profundo

gensim

- Librería de PLN en Python especializada en modelos estadísticos de texto
- Muy utilizada para análisis semántico distribuido (representa el significado de palabras y documentos mediante vectores aprendidos a partir de sus contextos)
- Sus principales funcionalidades son:
 - Representaciones distribucionales: Word2Vec, Doc2Vec.
 - Cálculo de similitud semántica entre palabras y documentos
 - Modelado de temas (Topic modeling): Latent Dirichlet Allocation (LDA)
 - Permite agrupación (clustering) de documentos a partir de representaciones semánticas

Ventajas: Muy eficiente en memoria. Adecuada para trabajar con grandes colecciones de documentos. Ideal para análisis exploratorio y comprensión global de corpus

Limitaciones: No proporciona análisis lingüístico (POS, parsing, NER, etc.). Modelos basados en contexto fijo (no contextuales). En muchas tareas ha sido superada por modelos Transformer

fasttext

- Librería desarrollada por Facebook para representaciones distribucionales (vectores) de texto.
- Diseñada para clasificación de texto y embeddings eficientes
- Funcionalidades principales
 - Soporte multilingüe (más de 150 idiomas)
 - Clasificación de texto supervisada
 - Word embeddings basados en subpalabras (n-gramas de caracteres). Incorpora información morfológica gracias a las subpalabras. Permite calcular similitud semántica entre palabras y textos

Ventajas: Muy rápida y eficiente. Robusta frente a palabras raras o desconocidas. Buen rendimiento en idiomas con pocos recursos

Limitaciones: No proporciona análisis lingüístico (POS, parsing, NER). Modelos **no contextuales**. Menos expresiva que los modelos basados en Transformers

Comparativa de herramientas de PLN

Herramienta	Enfoque principal	Tipo de semántica	Tareas destacadas	Uso típico
NLTK	Lingüístico / académico	Simbólica (WordNet)	Tokenización, stemming, lematización basada en WordNet , POS, recursos léxicos	Docencia, aprendizaje de conceptos
spaCy	Pipelines y aplicaciones	Embeddings	Tokenización, lematización automática, POS, dependencias, NER, similitud	Aplicaciones reales, industria
Gensim	Modelos estadísticos	Embeddings	Topic modeling, Word2Vec, Doc2Vec, similitud, clustering semántico	Análisis exploratorio de corpus
fastText	Representaciones eficientes	Embeddings	Embeddings subword, clasificación, PLN multilingüe	PLN rápido y multilingüe

Resumen

- Existen distintas herramientas de PLN, diseñadas con objetivos y enfoques diferentes
- Cada herramienta está orientada a un contexto de uso distinto:
 - NLTK → docencia y análisis lingüístico
 - spaCy → desarrollo de aplicaciones y pipelines de PLN
 - Gensim → análisis semántico y exploración de corpus
 - fastText → Clasificación de textos y representación semántica. PLN eficiente y multilingüe

No existe una herramienta “mejor” en general: la elección depende de la tarea, los datos y el contexto de aplicación

OpenCourseWare
Procesamiento de Lenguaje Natural con
Aprendizaje Profundo,

Gracias!!!

<https://github.com/iseaura>