

**Procesamiento de Lenguaje Natural con
Aprendizaje Profundo,
Máster en Ciencia y Tecnología Informática
Curso 2025-2026**

**Tema 1.5. Representación de textos. Modelo
Bolsa de Palabras y TF-IDF**

Índice

- Introducción: representación numérica del texto
- Bag of Words (BoW)
- Limitaciones del modelo Bag of Words
- TF-IDF
- Ventajas y desventajas de BoW y TF-IDF
- Implementación práctica.
- Resumen

Objetivos

Al finalizar esta presentación, el estudiante será capaz de:

- Comprender la necesidad de **transformar el texto en representaciones numéricas**.
- Entender el funcionamiento del modelo **Bag of Words (BoW)**.
- Conocer el método **TF-IDF** y su diferencia respecto a BoW.
- Identificar las **limitaciones** de estas representaciones en términos de semántica y estructura
- Reconocer por qué estas limitaciones motivan el uso de **representaciones más avanzadas**

Introducción

- Para que un algoritmo pueda procesar texto, es necesario transformarlo en una representación numérica.
- Una vez que el texto ha sido **preprocesado**, puede representarse como un **vector numérico** para su uso en modelos de aprendizaje automático.

Enfoques más comunes:

- **Modelo de bolsa de palabras (Bag of Words)**
- **Modelo TF-IDF**
- Modelos no contextuales (word embedding)
- Modelos contextuales (embeddings contextuales) (modelos actuales)

Modelo Bolsa de Palabras (Bag of Words, BoW)

- Dada una colección de textos preprocesados, se construye un **vocabulario** con todas las palabras distintas del corpus.
- Cada palabra del vocabulario se asocia a un **índice** (el orden es arbitrario).
- Cada texto se representa como un **vector** de dimensión igual al tamaño del vocabulario.
- Cada componente del vector indica el **número de veces** que la palabra aparece en el texto.

Modelo Bolsa de Palabras (Bag of Words, BoW)

perfil vascular, con episodios
de episodios de agresividad y
nocturnidad
agitación
episodios de agresividad y
nocturnidad
agitación
episodios de agresividad y
nocturnidad
agitación
nocturnidad
-intervención de
colecistectomía, catarata de
od, fractura de cadera
izquierda - ingresada en
septiembre del 03 en FHA
por luxación de la prótesis
de cadera Tratamiento
habitual, besitrán, digoxina,
dilutol 10 fraxiparina



Fuente: Smashicons [Flaticon](#)



0	ball
1	big
2	cat
3	moon
4	small
5	table
6	tree
7	window
8	zoo

**Conjunto textos de
entrenamiento**

Bolsa de Palabras

Vocabulario

Modelo Bolsa de Palabras (Bag of Words, BoW)

Texto:

The big cat is on the table and the small cat in the window.

Texto preprocesado:

~~The big cat is on the table and the small cat in the window.~~

ball	big	cat	moon	small	table	tree	window	zoo
0	1	2	0	1	1	0	1	0

Modelo Bolsa de Palabras (Bag of Words, BoW)

D1: ~~The big cat is on the table and the small cat in the window~~

D2: ~~The table and the window are small~~

D2: ~~The moon and the small tree are big~~

	ball	big	cat	moon	small	table	tree	window	zoo
D1	0	1	2	0	1	1	0	1	0
D2	0	0	0	0	1	1	0	1	0
D3	0	1	0	1	1	0	1	0	0

Modelo TF-IDF

- Versión extendida del modelo bolsa de palabras.
- Cada texto es representado usando tf-idf de cada palabra en el vocabulario.
- Se utiliza **TF-IDF** porque consigue **disminuir** el **peso** de aquellas **palabras que son muy comunes** en la colección de textos.

TF-IDF

- Term frequency - inverse document frequency de la palabra w en el document d

$$\text{TF-IDF}(w,d) = \text{TF}(w,d) * \text{IDF}(w)$$

- $\text{TF}(w,d)$ = frecuencia de la palabra w en el documento d
- $\text{IDF}(w)$ = *inverse document frequency*. Logaritmo del cociente entre el número total de documentos (N) y el número de documentos que contienen a la palabra w

$$\text{IDF}(w) = \log\left(\frac{N}{|d \in D: w \in d|}\right)$$

Bolsa de Palabra

	ball	big	cat	moon	small	table	tree	window	zoo
D1	0	1	2	0	1	1	0	1	0
D2	0	0	0	0	1	1	0	1	0
D3	0	1	0	1	1	0	1	0	0

TF-IDF

	ball	big	cat	moon	small	table	tree	window	zoo
D1	0	0.17	0.95	0	0	0.17	0	0.17	0
D2	0	0	0	0	0	0.17	0	0.17	0
D3	0	0.17	0	0.47	0	0	0.47	0	0

Ventajas de los modelos BoW y TF-IDF

- Fáciles de implementar.
- Buenos resultados en tareas de clasificación de textos.

Desventajas de los modelos BoW y TF-IDF

- Los vectores tienen una gran dimensionalidad (tamaño del vocabulario) y la información es escasa y dispersa (muchos 0s).
- No pueden capturar información semántica. Por ejemplo, estas dos expresiones tienen un significado similar, pero tendrán vectores diferentes:
 - *Edema de glotis != hinchazón de la laringe*

Desventajas de los modelos BoW y TF-IDF

- No tienen en cuenta la posición de las palabras. De esta forma, las dos siguientes oraciones son representadas con el mismo vector, pero sin embargo tienen significados opuestos:
 - *The hotel was very good and not expensive !=*
 - *The hotel was very expensive and not good*

Cómo implementar los modelos BoW y TF-IDF

- Aunque sería posible desarrollar ambos modelos paso a paso, afortunadamente, la librería [sklearn](#), ya hace este trabajo para nosotros y nos proporciona clases [CountVectorizer](#) para el modelo bolsa de palabras, y [TfidfVectorizer](#) para el modelo tf-idf.
- En el siguiente [link](#) puedes encontrar un ejemplo de cómo utilizar estas clases.

Resumen

- PLN basado en aprendizaje automático implica representación de textos (transformación a vectores numéricos).
- Algunas técnicas de preprocesamiento permiten reducir la variabilidad del lenguaje.
- Bolsa de palabras y tf-idf basados en la frecuencias de las palabras en los textos.
- Son modelos eficientes.
- Sin embargo, presentan algunas limitaciones: alta dimensionalidad y su imposibilidad de capturar información semántica.

Procesamiento de Lenguaje Natural con Aprendizaje Profundo,

Gracias!!!

<https://github.com/isegura/PLN-tema1>