

Tema 1 – Introducción

Índice

- Tecnologías de Lenguaje:
 - Tecnologías del Habla,
 - Procesamiento de Lenguaje Natural (PLN)
 - Lingüística computacional
- Un poco de historia sobre PLN
- Aplicaciones PLN
 - Traducción Automática
 - Generación de Resúmenes
 - Recuperación de Información
 - Extracción de Información
 - Clasificación de textos
 - Asistentes Virtuales

Tecnologías del Lenguaje

- Conjunto de **herramientas y técnicas** que permiten a los ordenadores **comprender, interpretar y generar lenguaje humano**, tanto en forma de **voz (Tecnologías del Habla)** como en **texto (Procesamiento de Lenguaje Natural)**.

Tecnologías del Lenguaje

Tecnologías del habla: sistemas automáticos capaces de comprender y generar lenguaje humano en formato voz. Algunos ejemplos:

- **Reconocimiento de voz** (voz → texto). *Ejemplos:* Traductor de Google, Speechnotes, entrada por voz en Google.
- **Síntesis de voz** (texto → voz). Ejemplos. NaturalReader, Traductor de Google
- **Asistentes de voz** (Alexa, Siri, etc.)

Procesamiento del Lenguaje Natural (PLN): sistemas automáticos capaces de comprender y generar lenguaje humano en formato texto. Algunos ejemplos:

- Corrección gramatical y ortográfica
- Traducción automática
- Clasificación de textos
- Análisis de sentimientos
- Resúmenes automáticos y simplificación de textos
- Asistentes virtuales y chatbots

Lingüística computacional

- Disciplina interdisciplinar que estudia el **lenguaje humano** mediante **modelos computacionales**, combinando conocimientos de **lingüística** e **informática**.
- Su principal objetivo es modelar y explicar las **propiedades estructurales y semánticas** del lenguaje para su tratamiento automático.

Lingüística computacional. Ámbitos

Análisis morfológico: estructura interna de las palabras.

Palabra: *hablábamos*

Descomposición morfológica:

- **habl-** → raíz léxica (*hablar*)
- **-á-** → vocal temática (primera conjugación)
- **-ba-** → morfema de tiempo y aspecto (pretérito imperfecto)
- **-mos** → morfema de persona y número (1ª persona plural)

Analizador morfológico Cervantes Virtual

Lingüística computacional. Ámbitos

Análisis sintáctico: estructura de las oraciones.

Oración: *El estudiante analiza el texto.*

Estructura sintáctica

- **Sintagma nominal (SN)**
 - *El estudiante* → **sujeto**
- **Sintagma verbal (SV)**
 - *analiza el texto* → **predicado**
 - *analiza* → núcleo verbal
 - *el texto* → complemento directo (SN)

Herramienta Análisis Sintáctico Airbro

Lingüística computacional. Ámbitos

Análisis sintáctico: estructura de las oraciones.



Lingüística computacional. Ámbitos

Análisis semántico: representación del significado.

Oración: *Juan compró un libro.*

Representación del significado (roles semánticos):

- **Acción:** comprar
- **Agente:** Juan (quién realiza la acción)
- **Objeto:** un libro (qué se compra)

Por qué es importante?

- Permite modelar aspectos básicos del significado, como los participantes y la acción principal.

Herramienta Semantic Role Labelling

Lingüística computacional. Ámbitos

Análisis pragmático: uso del lenguaje en su contexto.

Ejemplo en asistentes conversacionales

- **Usuario:** *Tengo frío.*
- **Significado literal:** El usuario informa sobre su estado (sensación de frío).
- **Interpretación pragmática:** El usuario expresa una **intención implícita** (solicitud de ayuda o acción).

Respuesta posible del asistente (ej. Alexa): *¿Quieres que suba la calefacción?*

¿Por qué es importante? La pragmática permite al asistente inferir la intención del usuario y generar una respuesta adecuada al contexto, más allá del significado literal.

Lingüística computacional. Ámbitos

ChatGPT 5.2 ▾

Pragmática

Estoy aburrida

Uff, el aburrimiento ataca 😓

Vamos a arreglar eso rápido. Elige tu *antídoto*:

1 Juego exprés

- *Verdad o reto* versión light
- *20 preguntas* (piensa algo y lo adivino)
- *Adivina la canción* con emojis 🎵

2 Mini reto creativo

- Te escribo un microcuento de 5 líneas con una palabra que elijas
- Hacemos una historia absurda a turnos
- Te invento un horóscopo fake pero sospechosamente acertado 🌙

3 Chisme intelectual

- Dato curioso random que te vuele la cabeza
- Debate inútil pero importante (ej: ¿la pizza con piña es crimen o arte?)

4 Desahogo

- Me cuentas qué te aburre exactamente y lo destripamos juntas 🍷

Di un número o proponme algo tú. Estoy lista 🤖🌟



Lingüística computacional. Ámbitos

Diseñar, construir y anotar **recursos lingüísticos** que permiten el desarrollo y la evaluación de sistemas de PLN.

- **Corpus anotados**
- **Léxicos, diccionarios computacionales y ontologías.**

¿Por qué son importantes?

Estos recursos constituyen la base sobre la que se entrenan, evalúan y comparan los sistemas de PLN.

Ejercicio

Dadas las siguientes tareas, indicar **qué nivel de la lingüística computacional** interviene principalmente (morfología, sintaxis, semántica, pragmática):

- Detectar el sujeto de una oración
- Identificar quién hace qué a quién
- Interpretar “Tengo frío” como una petición
- Separar raíz y morfemas de una palabra


Lingüística computacional vs PLN

Lingüística Computacional

- Objetivo: **modelar y entender** el lenguaje humano
- Enfoque Teórico y explicativo
- Su principal contribución es la creación de recursos lingüísticos (corpus, diccionarios, etc) y desarrollo de teorías lingüísticas

Procesamiento del Lenguaje Natural

- Objetivo: **construir sistemas automáticos** que usen y generen lenguaje humano
- Enfoque Práctico y orientado al rendimiento




Evolución PLN

Un poco de historia sobre PLN

Evolución PLN



Evolución PLN



1950s

Test de Turing

**Primer
experimento en
traducción
automática
(Georgetown-IBM
1954)**

$S \rightarrow NP\ V\ NP$
 $NP \rightarrow (D)\ (A)\ N\ (PP)$
 $VP \rightarrow V\ (NP)\ (PP)$
 $PP \rightarrow P\ (NP)$


1960s–1970s

Informe ALPAC

Enfoques simbólicos y
basados en reglas


Primeros analizadores
sintácticos

Primeros sistemas de
diálogo: ELIZA,
SHRDLU



1980s–2000s

Enfoques
estadísticos y
aprendizaje
automático +
corpora



2010s -

Enfoques
Aprendizaje
Profundo (word
embeddings, redes
recurrentes,
transformers, LLMs,
etc)

Test de Turing

Propuesto por **Alan Turing** en 1950

Participantes: un juez humano, un humano y Una máquina

El juez se comunica **sólo por texto** con los otros dos. No puede verlos ni oírlos.

Su tarea es decidir **quién es el humano y quién es la máquina.**

Si el juez **no acierta de forma fiable**, se dice que la máquina pasa el test.

Test de Turing – Eugene Goostman, 2014

- **Eugene Goostman** es un **chatbot** (texto) creado para **participar en pruebas del test de Turing**.
- Simulaba ser un adolescente ucraniano de 13 años. Esa identidad explicaba sus errores gramaticales, respuestas vagas, malentendidos, etc.
- Fue el primer sistema que superó el Test de Turing (un porcentaje creyó que era una persona).
- Su evaluación fue polémica (porcentaje limitado de jueces, duración muy breve de las conversaciones, etc).



Test de Turing – LLMs

Los **LLMs actuales (ChatGPT, Gemini, LLaMa, etc)** pueden generar texto **fluido, coherente y empático**, por lo que **podrían pasar el test de Turing** en conversaciones breves.

Sin embargo no tienen comprensión, inteligencia real, conciencia ni experiencia del mundo. Su comportamiento se basa en **patrones estadísticos del lenguaje**, no en razonamiento humano.


Hoy, el test de Turing es un **referente histórico**, pero **no es una evaluación adecuada** para medir las capacidades reales de los LLMs en PLN.

Georgetown – IBM experiment

- Primer experimento en traducción automática (9 Enero 1954):
 - ruso – inglés
 - basado en 6 reglas y un diccionario de 250 términos.
 - capaz de traducir 60 oraciones
 -

Russian (Romanized)	English translation
Mi pyeryedayem mislyi posryedstvom ryechyi.	We transmit thoughts by means of speech.
Vyelyichyina ugla opryedyelayetsya otnoshenyiyem dlyini dugi k radyiusu.	Magnitude of angle is determined by the relation of length of arc to radius.
Myezhdunarodnoye ponyimaniye yavlyayetsya vazhnim faktorom v ryeshenyiyi polyityichyeskix voprosov.	International understanding constitutes an important factor in decision of political questions.

Evolución PLN



1950s

Test de Turing

Primer experimento en traducción automática (Georgetown-IBM 1954)

$S \rightarrow NP V NP$
 $NP \rightarrow (D) (A) N (PP)$
 $VP \rightarrow V (NP) (PP)$
 $PP \rightarrow P (NP)$


1960s–1970s

Informe ALPAC

Enfoques simbólicos y basados en reglas


Primeros analizadores sintácticos

Primeros sistemas de diálogo: ELIZA, SHRDLU



1980s–2000s

Enfoques estadísticos y aprendizaje automático + corpora



2010s -

Enfoques Aprendizaje Profundo (word embeddings, redes recurrentes, transformers, LLMs, etc)

Informe ALPAC (1966)

- Automatic Language Processing Advisory Committee, financiado por EEUU.
- Estudiar los avances en traducción automática (1954-1966)
- Ruso-Inglés, **enfoque basado en reglas**
- Se concluyó que la traducción automática era más lenta, más costosa y de menor calidad que la traducción humana asistida por herramientas simples.
- Se recomendó reducir drásticamente la financiación. Estancamiento de la investigación durante años

Enfoques simbólicos y basados en reglas

Primero enfoques en PLN

El conocimiento lingüístico se representa mediante **símbolos y reglas explícitas**, definidas manualmente.

No hay aprendizaje a partir de datos.

Representación del conocimiento **explícita e interpretable**.

Fáciles de analizar, pero difíciles de escalar.

Primeros analizadores sintácticos

Basados en **gramáticas generativas**, propuestas por **Noam Chomsky**.

La sintaxis se describe mediante **reglas formales** que genera oraciones bien formadas.

Base histórica del parsing (análisis sintáctico) en PLN. El análisis sintáctico consiste en comprobar si una oración puede derivarse a partir de esas reglas.

Ejemplos de reglas de Gramáticas Libres de Contexto (*Context-Free Grammar, CFG*):

- $S \rightarrow SN\ SV$
- $SN \rightarrow Det\ N$
- $SV \rightarrow V\ SN$

Con esas reglas es posible analizar la oración “el niño come la manzana”

- $Det \rightarrow el\ | \ la$
- $N \rightarrow niño\ | \ manzana$
- $V \rightarrow come$

Eliza, 1966

Uno de los **primeros sistemas de diálogo**, creado por **Joseph Weizenbaum**

Eliza simulaba ser un terapeuta y podía mantener una conversación usando **reglas simples y patrones**, sin comprensión real del lenguaje.

Su principal estrategia era reformular las frases del usuario como preguntas (estilo terapeuta).

Es un referente histórico del PLN y los chatbots.

Usuario: Me siento triste últimamente.

ELIZA: ¿Por qué dices que te sientes triste últimamente?

Usuario: Porque tengo problemas con mi familia.

ELIZA: ¿Puedes hablarme más de tus problemas con tu familia?

Usuario: Mi padre no me entiende.

ELIZA: ¿Crees que es importante que tu padre te entienda?

Usuario: Sí, eso me afecta mucho.

ELIZA: ¿Por qué crees que eso te afecta mucho?

SHRDLU, 1970


SHRDLU, desarrollado por **Terry Winograd**, fue uno de los primeros sistemas que **entendía y razonaba con lenguaje natural** en un dominio limitado.

Permitía interactuar **en lenguaje natural** con un **mundo de bloques** simulado, entendiendo órdenes, y ejecutando sus acciones asociadas.


Funcionaba muy bien en un dominio cerrado y controlado

No es escalable a lenguaje real y abierto

Demostró el potencial del PLN, pero también los **límites de los enfoques simbólicos**.



Evolución PLN



1950s

Test de Turing

Primer experimento en traducción automática (Georgetown-IBM 1954)

$S \rightarrow NP V NP$
 $NP \rightarrow (D) (A) N (PP)$
 $VP \rightarrow V (NP) (PP)$
 $PP \rightarrow P (NP)$


1960s–1970s

Informe ALPAC

Enfoques simbólicos y basados en reglas


Primeros analizadores sintácticos

Primeros sistemas de diálogo: ELIZA, SHRDLU



1980s–2000s

Enfoques estadísticos y aprendizaje automático



2010s -

Enfoques Aprendizaje Profundo (word embeddings, redes recurrentes, transformers, LLMs, etc)

Enfoques estadísticos y aprendizaje automático

Uso de **corpus y datasets reales**.

Modelos **estadísticos/probabilísticos**: n-gramas, HMMs

Aprendizaje automático clásico: SVM, Regresión Logística, Naïve Bayes, CRFs, árboles de decisión.

Evaluación cuantitativa y comparativa.

Mayor **robustez y escalabilidad** que los enfoques de reglas.

Dependencia de **features diseñadas manualmente**. Ejemplos de features: n-gramas de palabras o caracteres, etiquetas morfosintácticas, mayúsculas, sufijos, prefijos, diccionarios, listas de palabras, posición en la frase.

Base directa del PLN moderno.

Modelo probabilístico n-gramas

A partir de un corpus se calculan **frecuencias de n-gramas** (unigramas, bigramas, etc.). En este ejemplo, vamos a suponer que tenemos un corpus muy pequeño, y sólo vamos a obtener las frecuencias de los unigramas y bigramas::

Corpus (muy pequeño):

el niño come la manzana
el niño come pan
la niña come la manzana

Palabra	Frecuencia
el	2
la	3
niño	2
niña	1
manzana	2
come	3
pan	1

Palabra	Frecuencia
el niño	2
niño come	2
come la	2
la manzana	2
come pan	1
la niña	1
niña come	1

Modelo probabilístico n-gramas

El siguiente paso es transformar las frecuencias en probabilidades condicionales:

$$P(w_i \mid w_{i-1}) = \frac{\text{freq}(w_{i-1} w_i)}{\text{freq}(w_{i-1})}$$

Por ejemplo, $P(\text{niño} \mid \text{el}) = \text{freq}(\text{el niño}) / \text{freq}(\text{el}) = 2 / 2 = 1$

Modelo probabilístico n-gramas

El modelos nos **permite predecir la palabra más probable** que sigue a una palabra dada o secuencia de palabras. Por ejemplo:

$$P(\text{la} \mid \text{come}) = \text{freq}(\text{come la}) / \text{freq}(\text{come}) = \frac{2}{3}$$

$$P(\text{pan} \mid \text{come}) = \text{freq}(\text{come pan}) / \text{freq}(\text{come}) = \frac{1}{3}$$

Es decir, es más probable que después de “come” venga “la” que “pan”

Modelo probabilístico n-gramas

Supongamos que tenemos un **modelo de bigramas** (no disponemos de frecuencias para n-gramas con $n \geq 3$).

La idea es que el modelos nos permita estimar la siguiente palabra a una secuencia de palabras.

Por ejemplo, queremos calcular la probabilidad de la oración “el niño come la manzana”.

Idealmente, querríamos estimar probabilidades como:

- $P(\text{manzana} \mid \text{el niño come la})$
- $P(\text{la} \mid \text{el niño come})$
- $P(\text{come} \mid \text{el niño})$

Estas probabilidades usan **todo el contexto previo**.

Modelo probabilístico n-gramas

Esto es difícil de estimar por escasez de datos → **aproximación:** usamos solo la palabra anterior.

El niño come la manzana

$$P \approx P(\text{el}) \cdot P(\text{niño} \mid \text{el}) \cdot P(\text{come} \mid \text{niño}) \cdot P(\text{la} \mid \text{come}) \cdot P(\text{manzana} \mid \text{la})$$

Con esta aproximación, se pierde contexto, pero el sistema se puede implementar.

Modelo probabilístico n-gramas

El niño come la manzana

$$P \approx P(\text{el}) \cdot P(\text{niño} \mid \text{el}) \cdot P(\text{come} \mid \text{niño}) \cdot P(\text{la} \mid \text{come}) \cdot P(\text{manzana} \mid \text{la})$$

- $P(\text{el}) = 2/14$
- $P(\text{niño} \mid \text{el}) = \text{freq}(\text{el niño}) / \text{freq}(\text{el}) = 2 / 2 = 1$
- $P(\text{come} \mid \text{niño}) = \text{freq}(\text{niño come}) / \text{freq}(\text{niño}) = 2 / 2 = 1$
- $P(\text{la} \mid \text{come}) = \text{freq}(\text{come la}) / \text{freq}(\text{come}) = 2 / 3$
- $P(\text{niña} \mid \text{la}) = \text{freq}(\text{la niña}) / \text{freq}(\text{la}) = 2 / 3$

$$= 2/14 * 1 * 1 * 2/3 * 2/3 = 4/63 = 0.063$$

Es decir, la probabilidad de que se de el bigrama “el niño” es del 100%, en ese corpus (ojo, es un corpus muy pequeño, no representativo)

Modelo probabilístico n-gramas

Ahora podemos calcular la probabilidad de una oración completa (aplicando la regla de la cadena):

El niño come la manzana

$$P \approx P(\text{el}) \cdot P(\text{niño} \mid \text{el}) \cdot P(\text{come} \mid \text{niño}) \cdot P(\text{la} \mid \text{come}) \cdot P(\text{manzana} \mid \text{la}) =$$

- $P(\text{el}) = 2/14$
- $P(\text{niño} \mid \text{el}) = \text{freq}(\text{el niño}) / \text{freq}(\text{el}) = 2 / 2 = 1$
- $P(\text{come} \mid \text{niño}) = \text{freq}(\text{niño come}) / \text{freq}(\text{niño}) = 2 / 2 = 1$
- $P(\text{la} \mid \text{come}) = \text{freq}(\text{come la}) / \text{freq}(\text{come}) = 2 / 3$
- $P(\text{manzana} \mid \text{la}) = \text{freq}(\text{la manzana}) / \text{freq}(\text{la}) = 1 / 3$

$$= 2/14 * 1 * 1 * 1/3 * 2/3 = 2/63 = 0.032$$

Modelo probabilístico n-gramas


Ahora podemos comparar ambas oraciones

el niño come la manzana $\rightarrow \approx 0.063$

el niño come la niña $\rightarrow \approx 0.032$

El modelo considera la primera **más probable (más “natural”)** que la segunda.

Evolución PLN



1950s

Test de Turing

Primer experimento en traducción automática (Georgetown-IBM 1954)

$S \rightarrow NP V NP$
 $NP \rightarrow (D) (A) N (PP)$
 $VP \rightarrow V (NP) (PP)$
 $PP \rightarrow P (NP)$


1960s–1970s

Informe ALPAC

Enfoques simbólicos y basados en reglas


Primeros analizadores sintácticos

Primeros sistemas de diálogo: ELIZA, SHRDLU



1980s–2000s

Enfoques estadísticos y aprendizaje automático



2010s -

Enfoques Aprendizaje Profundo (word embeddings, redes recurrentes, transformers, LLMs, etc)

Aprendizaje profundo

Uso de **redes neuronales profundas** entrenadas con grandes datasets.

Aprendizaje automático de representaciones (menos *features* manuales).

Modelos:

- Word embeddings (Word2Vec, GloVe).
- Redes convolucionales (CNNs) y recurrentes (RNNs, LSTM, GRU).
- Transformers y atención.
- Modelos de lenguaje grandes (LLMs).

Aprendizaje profundo


Ventajas:

- Mejor manejo de **contexto** y **ambigüedad**.
- Rendimiento muy superior en múltiples tareas de PLN.


Limitaciones

- Alto coste computacional.
- Menor interpretabilidad.

Estado del arte actual en PLN.



Aplicaciones PLN



Aplicaciones PLN

Traducción Automática

Traducción automática

Detected: **Alemán** | inglés | español | francés ▼

Mein Name ist Isabel, ich komme aus Spanien. Ich bin 50 Jahre alt und habe zwei Töchter. ✕



89 / 5.000 

↔ **español** | inglés | francés ▼

Mi nombre es Isabel, vengo de España. Tengo 50 años y dos hijas. ☆

Enviar comentarios



Traductor de Yandex
Página web



Amazon Translate

Traducción automática fluida y precisa



Microsoft Translator 4.4


Translate 100+ languages
Microsoft Corporation

#155 in Productivity
★★★★★ 4.8 • 159.5K Ratings

Free

Traducción automática (enfoques)

```
# texto_es det + nombre + adjetivo  
  
det = extraer_det(texto_es)  
nombre = extraer_nombre(texto_es)  
adjetivo = extraer_adj(texto_es)  
  
det_en = diccionario_es_en[det]  
nombre_en = diccionario_es_en[nombre]  
adjetivo_en = diccionario_es_en[adjetivo]  
texto_en = det_en + " " + adjetivo_en + " " + nombre_en
```



1950s-1980s

Reglas y
diccionarios

1990s-2010s

Corpus paralelos
y modelos
estadísticos

2010s-...

Redes
neuronales
profundas y
LLMs

Traducción automática basada en reglas

Español:

Las casas bonitas

Traducción literal (solo diccionario):

 *The houses beautiful*

Regla sintáctica (inglés):

Det + N + Adj $\rightarrow$ Det + Adj + N

Traducción correcta (diccionario + reglas):

 *The beautiful houses*

Traducción automática basada en reglas

Limitaciones de lo enfoques basados en reglas: una misma expresión puede tener **distintas traducciones** según el **significado y el contexto**.

Por ejemplo, ***pensar en***, se podría traducir como:

- *think about* → reflexionar (Think about something)
- *think of* → imaginar / recordar (Think of a solution; Think of you)
- *think over* → evaluar con calma (think over an offer)

No existe una **regla única** válida en todos los casos.

Por tanto, las reglas no escalan bien cuando el significado depende del contexto.

Traducción automática basada en reglas

Limitaciones de la traducción basada en reglas (expresiones idiomáticas)

Español: *Está lloviendo a cántaros*

Traducción literal (diccionario + reglas): ❌ *It's raining jugs*

Traducción correcta: ✅ *It's raining cats and dogs*

Problema:

- *a cántaros* es una **expresión idiomática**.
- Su significado **no es composicional** (es decir, no se obtiene a partir del significado de sus partes)

Las reglas fallan cuando el significado no se obtiene a partir de las palabras individuales. Sería necesario añadir una regla específica y un diccionario de expresiones idiomáticas

Traducción automática basada en reglas

Ventajas

- Fáciles de implementar e interpretar.
- Útiles en **dominios cerrados** y controlados.
- No requieren grandes corpus de datos.

Limitaciones

- Alto coste de **desarrollo y mantenimiento**.
- No se pueden reutilizar a otros idiomas.
- Escalan mal a lenguaje real y abierto.
- Manejo pobre del **contexto** y la **ambigüedad**
 - Me senté en el banco -> bench
 - Abrí una cuenta en el banco -> bank
- Fallan con **expresiones idiomáticas** y significado no composicional.

Traducción automática (enfoques)



Traducción automática estadística

Uso de **corpus paralelos** (oraciones alineadas en dos lenguas).

El sistema aprende **probabilidades de traducción** a partir de ejemplos reales.

Traducción automática estadística

Un corpus paralelo contiene textos en dos lenguas con oraciones que son traducciones entre sí.

Están alineados a nivel de oración. Es decir, cada oración en la lengua origen, se empareja con su traducción en la lengua destino. Por ejemplo

- ES: *El niño come la manzana*
- EN: *The boy eats the apple*

Permite aprender correspondencias de traducción a partir de datos reales.

Ejemplo de corpus paralelo

- **Europarl**: transcripciones de los debates del **Parlamento Europeo**.
- Disponible en múltiples idiomas oficiales de la UE (inglés–francés, inglés–alemán, inglés–español, etc.).

Traducción automática estadística

Alineación a nivel de sintagma (phrase alignment): en lugar de alinear oraciones completas, se alinean **grupos de palabras (sintagmas)** que se traducen juntos. Por ejemplo:

- ES: *a cántaros* → EN: *cats and dogs*
- ES: *el niño* → EN: *the boy*
- ES: *la manzana* → EN: *the apple*

La alineación a nivel de sintagma captura unidades de significado y reordenamientos que la alineación por oración no puede modelar.

Produce traducciones **más naturales y precisas** que la alineación solo a nivel de oración.

Traducción automática estadística

Inglés	Español
"The European Parliament"	"El Parlamento Europeo"
"is committed to ensuring"	"está comprometido a garantizar"
"that all citizens are represented."	"que todos los ciudadanos estén representados."

Alineamiento de frases de la primera oración:

"The European Parliament is committed to ensuring that all citizens are represented."

Traducción automática estadística

- A partir de un **corpus paralelo**, se aprenden **frecuencias de traducción** entre sintagmas de dos lenguas.
- Por ejemplo, para el sintagma, **en su casa**, el modelo podría observar las siguientes traducciones en el corpus:

Traducción	Frecuencia
At her house	45
At his house	44
In her house	13
In his house	15

Las más probables son **“at her house”** y **“at his house”**

Traducción automática estadística

Utilizando información de contexto de la oración

“**She’s** always _ on weekends”

se podría deducir fácilmente que la traducción correcta es “at her house”

“**She’s** always **at her house** on weekends”

Traducción automática estadística

Ventajas



- Aprende traducciones a partir de corpus paralelos.
- Los modelos probabilísticos son interpretables
- Menos reglas manuales que los sistemas basados en reglas.
- Se adaptan mejor a la variación lingüística.

Limitaciones

- Requiere grandes corpus paralelos.
- Requiere alineación a nivel de sintagma
- Manejo limitado de contexto largo.

Traducción automática (enfoques)

```
# texto_es det + nombre + adjetivo  
  
det = extraer_det(texto_es)  
nombre = extraer_nombre(texto_es)  
adjetivo = extraer_adj(texto_es)  
  
det_en = diccionario_es_en[det]  
nombre_en = diccionario_es_en[nombre]  
adjetivo_en = diccionario_es_en[adjetivo]  
texto_en = det_en + " " + adjetivo_en + " " + nombre_en
```



1950-1980

Reglas y
diccionarios

1980-2010

Corpus paralelos
y modelos
estadísticos

2010-...

**Redes neuronales
profundas**


Traducción automática neuronal

Corpus paralelos + redes neuronales profundas.

La traducción se aprende como una **secuencia a secuencia**.

Pueden modelar oraciones completas

Arquitecturas **Seq2Seq (RNN -> transformers)**




Traducción automática neuronal

Ventajas

- Mejor manejo de contexto largo.
- Traducciones más fluidas y coherentes.
- Menor ingeniería manual.

Limitaciones

- Alto coste computacional.
- Requiere corpus paralelos muy grandes.
- Menor interpretabilidad (caja negra)



Aplicaciones PLN

Generación de resúmenes

Generación de resúmenes (Text summarization)

- Objetivo: Producir un resumen que sintetice la información más relevante de un texto o conjunto de textos de entrada.
- Ejemplos de aplicaciones:
 - Resumen de la historia clínica de un paciente.
 - Resumen de emails, artículos o libros, etc...
 - Simplificación de un texto en una versión más sencilla (por ejemplo, una ley, un prospecto de un medicamento)

Generación de resúmenes. Enfoques

Extractiva: el resumen es creado a partir de palabras y oraciones que aparecen en el texto de entrada.

Abstractiva: el resumen generado es un texto nuevo que sintetiza la idea del texto original.

Generación de resúmenes

- Ejemplo Extractiva vs Abstractiva:
 - **Texto original:** *Yolanda Díaz en un acto de Sumar ha afirmado que existe una elite mundial preparando planes alternativos para poder huir del mundo en el caso de que nos vayamos al “carajo”.*

Generación de resúmenes

- Ejemplo Extractiva vs Abstractiva:
 - **Texto original:** Yolanda Díaz en un acto de Sumar ha afirmado que existe una elite mundial preparando planes alternativos para poder huir del mundo en el caso de que nos vayamos al “carajo”.
 - **Resumen extractivo:** Yolanda Díaz ha afirmado que existe una elite mundial preparando planes para poder huir del mundo.

Generación de resúmenes

- Ejemplo Extractiva vs Abstractiva:
 - **Texto original:** *Yolanda Díaz en un acto de Sumar ha afirmado que existe una elite mundial preparando planes alternativos para poder huir del mundo en el caso de que que nos vayamos al "carajo".*
 - **Resumen abstracto:** *Según Yolanda Díaz, existe una elite mundial **que planea** huir si el mundo **se va** al carajo.*

Generación de resúmenes

- Enfoques basados en reglas
- Enfoques basados en Aprendizaje Automático (clásico)
- Enfoques basados en Aprendizaje Profundo.

Generación de resúmenes

- Enfoques basados en **reglas**: seleccionar las oraciones más importantes:
 - Incluir la primera oración.
 - Excluir oraciones demasiado cortas o poco informativas.
 - Identificar los temas principales del texto. Seleccionar oraciones que contengan esos temas.
 - Uso de información estructural (títulos, palabras clave).

Generación de resúmenes

- Enfoques basados en en Aprendizaje Automático (clásico):
formulan el resumen como un **problema de clasificación o ranking de oraciones**.
 - Utilizan características lingüísticas y estadísticas:
 - posición de la oración (oraciones situadas al principio de un texto suelen ser más informativas)
 - Longitud (oraciones demasiado cortas o demasiado largas suelen ser menos informativas para un resumen)
 - TF-IDF (identificar y comparar fragmentos de texto relevantes, apoyando la selección y alineamiento de ejemplos de traducción)
 - Algoritmos típicos: regresión logística, SVM, árboles de decisión
 - Principalmente para resumen extractivo.

Generación de resúmenes

- Enfoques basados en **Aprendizaje Profundo**
 - Uso de redes neuronales profundas.
 - Entrenados con corpus paralelos (documento ↔ resumen).
 - Modelos actuales: RNN, Transformers
- Permiten generar resúmenes extractivos y abstractivos.

Generación de resúmenes

- Tarea muy compleja, que requiere:
 - Corpus paralelos (texto original – resumen) de gran tamaño.
 - No existe un resumen “perfecto”, lo que dificulta la evaluación.
 - Capacidad generar texto coherente, fluido y conciso.
 - Conocimiento profundo del significado del texto: El sistema debe ir más allá de palabras clave y capturar el significado global del texto.

Ejercicio

Dado el siguiente texto:

La traducción automática ha experimentado un gran avance en las últimas décadas. Los primeros sistemas se basaban en reglas lingüísticas escritas manualmente, lo que limitaba su cobertura y calidad. Posteriormente, los enfoques estadísticos utilizaron grandes corpus bilingües para aprender correspondencias entre lenguas. En los últimos años, los modelos neuronales han logrado mejoras significativas en fluidez y precisión. A pesar de estos avances, la traducción automática sigue presentando desafíos, especialmente en textos especializados y contextos complejos.

Ejercicio

1. Proponer un **resumen extractivo**, seleccionando una o dos oraciones del texto original.
2. Proponer un **resumen abstractivo**, redactado con tus propias palabras.
3. ¿Qué enfoque es más sencillo?

Generación de resúmenes. Métricas de evaluación

ROUGE-n es una métrica automática de evaluación de resúmenes que mide la similitud entre un resumen generado y uno de referencia contando la coincidencia de n-gramas (secuencias contiguas de n palabras) entre ambos textos.

$$\text{ROUGE-n} = \text{num_ngramas_comun} / \text{num_ngramas_ref}$$

donde:

- num_ngramas_comun : es el número de n-gramas que tienen en común ambos resúmenes
- Num_ngramas_ref: es el número total de n-gramas en el resumen de referencial

Generación de resúmenes. Ejemplo

Vamos a calcular ROUGE-1 para los dos siguientes resúmenes:

Resumen de referencia: *Juan compró un libro*

Resumen generado: *Juan compró el libro*

Generación de resúmenes. Ejemplo

Resumen de referencia: *Juan compró un libro*

Resumen generado: *Juan compró el libro*

Paso 1: Obtenemos los unigramas de cada resumen

- **Referencia:** Juan, compró, un, libro
- **Generado:** Juan, compró, el, libro

Generación de resúmenes. Ejemplo

Resumen de referencia: *Juan compró un libro*

Resumen generado: *Juan compró el libro*

Paso 1: Obtenemos los unigramas de cada resumen

- **Referencia:** Juan, compró, un, libro (4 unigramas)
- **Generado:** Juan, compró, el, libro (4 unigramas)

Paso 2: Contamos que unigramas tienen en común

- **Unigramas en común:** Juan, compró, libro (3 unigramas)

Generación de resúmenes. Ejemplo

Resumen de referencia: *Juan compró un libro*

Resumen generado: *Juan compró el libro*

Paso 1: Obtenemos los unigramas de cada resumen

- **Referencia:** Juan, compró, un, libro (4 unigramas)
- **Generado:** Juan, compró, el, libro (4 unigramas)

Paso 2: Contamos que unigramas tienen en común

- **Unigramas en común:** Juan, compró, libro (3 unigramas)

Paso 3: Cálculo de ROUGE-1 = $3 / 4 = 0.75$

El resumen generado recupera el **75 % del contenido léxico** del resumen de referencia.

Generación de resúmenes. Ejercicio

Vamos a calcular ROUGE-1 para los dos siguientes resúmenes:

Resumen de referencia: *Juan compró un coche*

Resumen generado: *Juan adquirió un vehículo*

· Generación de resúmenes. Ejercicio

Vamos a calcular ROUGE-1 para los dos siguientes resúmenes:

Resumen de referencia: *Juan compró un coche*

Resumen generado: *Juan adquirió un vehículo*

Solución:

Unigramas en común: Juan, un

$$ROUGE-1 = 2 / 4 = 0.5$$

Semánticamente los dos resúmenes dicen lo mismo, pero ROUGE-1 penaliza porque **solo compara palabras exactas**

Por tanto, ROUGE no es suficiente como métrica de evaluación porque **penaliza resúmenes que usan sinónimos**.

Ejercicio

Dado los siguientes resúmenes:

Resumen de referencia:

Juan compró un libro y lo leyó en casa.

Resumen generado:

Juan libro y compró leyó casa en un.

Calcula el valor de la métrica ROUGE-1.

¿Es un buen resumen?

Ejercicio

Resumen de referencia:

Juan compró un libro y lo leyó en casa.

Resumen generado:

Juan libro y compró leyó casa en un.

ROUGE-1= 1 , sin embargo, el resumen generado tiene una gramática incorrecta y es poco coherente.

Por tanto, ROUGE no es suficiente como métrica de evaluación porque no evalúa la calidad lingüística del resumen: gramática, la fluidez y la coherencia.

Ejercicio

Dado los siguientes resúmenes:

Resumen de referencia:

Juan compró un libro y lo leyó en casa.

Resumen generado:

Juan libro y compró leyó casa en un.

Calcula ahora el valor de la métrica ROUGE-2.

¿Qué indica ROUGE-2?

Ejercicio

Resumen de referencia: *Juan compró un libro y lo leyó en casa.*

Resumen generado: *Juan libro y compró leyó casa en un.*

Bigramas del resumen de referencia (8): juan compró, compró un, un libro, libro y, y lo, lo leyó, leyó en, en casa

Bigramas del resumen generado (7): juan libro, libro y, y compró, compró leyó, leyó casa, casa en, en un

Único bigrama en común : libro y

$$\text{ROUGE-2} = 1 / 8 = 0,125$$

El resumen generado **solo conserva el 12.5 % de los bigramas del resumen de referencia**

Ejercicio

Resumen de referencia:

Juan compró un libro y lo leyó en casa.

Resumen generado:

Juan compró en casa y lo leyó un libro.

Bigramas coincidentes: 5


(juan compró, en casa, y lo, lo leyó, un libro)

$$\text{ROUGE-2} = 5 / 8 = \mathbf{0.625}$$

El resumen generado conserva el 62.5 % de las secuencias de dos palabras del resumen de referencia, indicando una buena preservación del orden y la estructura.

Sin embargo, no es un buen resumen (falla en su interpretación semántica)

ROUGE no capta bien la fluidez ni la interpretación semántica del texto.



Aplicaciones PLN

Recuperación de
información

Recuperación de información



Fuente: firmbee, [Pixabay](#)

Dialnet^{plus} [Buscar](#) [Revistas](#) [Tesis](#) [Congresos](#) [Autores](#) [métricas](#) Español ▾

Buscar documentos

guerra civil española **Buscar**

▼ **Filtros** 6.014 documentos encontrados Relevancia ▾ 20 ▾

Tipo de documento

- ☐ Artículo de revista (3.087)
- ☐ Artículo de libro (1.888)
- ☐ Tesis (645)
- ☐ Libro (394)

Textos completos

- ☐ Sí (3.030)
- ☐ No (2.984)

Materias Dialnet

- ☒ Humanidades (6.014)
- ☐ Ciencias sociales (623)
- ☐ Filologías (292)
- ☐ Arte (210)
- ☐ Ciencias jurídicas (70)
- ☐ Psicología y educación (69)
- ☐ Economía y empresa (62)
- ☐ Tecnologías (37)

[Mostrar más...](#)

Submaterias Dialnet

☐ **Narrativa de guerra y Guerra Civil española**
Alicia Altied Vigil
Los nuevos historiadores ante la Guerra Civil española / coord. por Miguel Carlos Gómez Oliver , Octavio Ruiz-Manjón Cabeza , Vol. 2, 1990, ISBN 84-7807-023-0, págs. 289-306

☐ **Narrativa de guerra y Guerra Civil española**
Alicia Altied Vigil
Los nuevos historiadores ante la Guerra Civil española / coord. por Miguel Carlos Gómez Oliver , Octavio Ruiz-Manjón Cabeza , Vol. 2, 1990, ISBN 84-7807-023-0, págs. 289-306

☐ **Historias mínimas: las cartas en la Guerra Civil española:: las cartas en la Guerra Civil española**
Javier Cervera Gil
Hispania Nova: Revista de historia contemporánea, ISSN-e 1138-7319, N.º. 15, 2017, págs. 125-146
Resumen | Texto completo

☐ **La Guerra Civil española en la era de la Guerra Total**
Roger Chickering
Alcores: revista de historia contemporánea, ISSN 1886-8770, N.º. 4, 2007 (Ejemplar dedicado a: La Guerra Civil española en perspectiva comparada), págs. 21-35

uc3m Universidad Carlos III de Madrid
BIBLIOTECA

Identificarse

[¿Olvidó su contraseña?](#)

[¿Es nuevo? Regístrate](#)
Ventajas de registrarse

Selección



PubMed

tratamiento diabetes tipo 2

[Advanced](#) [Create alert](#) [Create RSS](#) [User Guide](#)

Sort by:

MY CUSTOM FILTERS

186 results

Page 1 of 19

RESULTS BY YEAR

PUBLICATION DATE

☐ 1 year
☐ 5 years
☐ 10 years
☐ Custom Range

TEXT AVAILABILITY

☐ [Treatment of type 2 diabetes mellitus in patients with chronic kidney disease. Grupo de Trabajo para el Documento de Consenso sobre el **tratamiento de la diabetes tipo 2** en el paciente con enfermedad renal crónica]. Gómez-Huelgas R, Martínez-Castelao A, Artola S, Górriz JL, Menéndez E; en nombre del Grupo de Trabajo para el Documento de Consenso sobre el tratamiento de la diabetes tipo 2 en el paciente con enfermedad renal crónica. Med Clin (Barc). 2014 Jan 21;142(2):85.e1-10. doi: 10.1016/j.medcli.2013.10.011. Epub 2013 Nov 21. PMID: 24268912 Spanish. Chronic kidney disease (CKD) and type 2 **diabetes mellitus** (T2DM) are highly prevalent chronic diseases, which represent an important public health problem and require a multidisciplinary management. T2DM is the main cause of CKD and it also causes a significa ...

☐ Cascadas de tamizaje y atención de la diabetes tipo 2 en México. Basto-Abreu A, Reyes-García A, Stern D, Torres-Ibarra L, Rojas-Martínez R, Aguilar-Salinas CA, Romero-Martínez M, Campos-Nonato I, López-Ridaaura R, Barrientos-Gutiérrez T. Salud Publica Mex. 2024 Aug 22;66(4, jul-ago):530-538. doi: 10.21149/16209.

Recuperación de información

Entrada: Colección de documentos




query

tratamiento diabetes tipo 2

**Sistema Recuperación
Información (Information
Retrieval)**



Salida: Conjunto de documentos relevantes




Aplicaciones PLN

Extracción de información

Extracción de información

Información no estructurado (textos) -> Estructurado (bases de datos, ontologías, etc)



Extracción de información. Tareas

Reconocimiento de Entidades Nombradas.
(Named Entity Recognition (NER))

Isabel

PER

vive en

Madrid

LOC


. Ella trabaja en la

UC3M

ORG


Extracción de información. Tareas

Resolución de la Correferencia



Extracción de información. Tareas

Extracción de relaciones



Extracción de información

- Principales aplicaciones:
 - Mejorar los sistemas de recuperación de información
 - Población de bases de datos, diccionarios, ontologías, taxonomías, etc.
 - Facilitan la implementación de sistemas de búsqueda de respuestas, y asistentes virtuales.
 - Ayudan en tareas como la traducción automática o generación de resúmenes

Extracción de información.

Isabel Segura-Bedmar: HULAT at SemEval-2023 Task 10: Data Augmentation for Pre-trained Transformers Applied to the Detection of Sexism in Social Media. SemEval@ACL 2023: 184-192. 13-14 July 2023 Toronto.



Autor: Isabel Segura-Bedmar.

Título: HULAT at SemEval-2023 Task 10: Data Augmentation for Pre-trained Transformers Applied to the Detection of Sexism in Social Media.

Conferencia: SemEval@ACL 2023

Páginas: 184-192

Fechas: 13-14 July 2023

Lugar: Toronto

Extracción de información.

Person p Loc l Org o Event e Date d Other z

Barack Hussein Obama II ✕ (born August 4, 1961 ✕) is an American ✕ attorney and politician who served as the 44th President of the United States ✕ from January 20, 2009 ✕, to January 20, 2017 ✕. A member of the Democratic Party ✕, he was the first African American ✕ to serve as president. He was previously a United States Senator ✕ from Illinois ✕ and a member of the Illinois State Senate ✕.

Extracción de información.

Miembros

Datos personales

Líneas

Proyectos

Publicaciones



Isabel Segura Bedmar

- Despacho: 2.2.B.05
- Campus: Campus de Leganés
- Teléfono: +34 91 624 59 61
- Correo electrónico: isegura@inf.uc3m.es

Biografía

Licenciada en Ciencias Matemáticas, Ciencias de la Computación por la Universidad Complutense de Madrid en 1998. Desde el año 2004 soy profesora del Departamento de Informática de la Universidad Carlos III de Madrid (UC3M) e investigadora en el Grupo Hulat (antes grupo Labda).

Doctora con mención europea en "Ciencia y Tecnología Informática" por la Universidad Carlos III de Madrid con la tesis "Application of Information Extraction Techniques to pharmacological domain: extracting drug-drug interactions". La tesis recibió el Premio Extraordinario de Doctorado en la UC3M en el 2010. Además, en 2011, obtiene el Premio Nacional de Investigación en Procesamiento de Lenguaje Natural (<http://www.sepln.org/investigacion/premio-sepln>), otorgado por la Sociedad Española de Procesamiento de Lenguaje Natural (SEPLN).

Mi actividad investigadora se centra en la disciplina del Procesamiento del Lenguaje Natural (PLN) en distintos dominios de aplicación, con un especial foco en la Extracción de Información en el dominio biomédico. En los últimos años, mis esfuerzos se han centrado en el estudio de métodos de deep learning y su aplicación para resolver tareas de reconocimiento de entidades, clasificación de textos (sentiment analysis, sarcasm detection, stance detection, etc), simplificación de textos y generación de resúmenes.

En este ámbito he publicado un total de **96 publicaciones científicas**, gran parte de ellas en revistas de alto factor de impacto. Índice H en Google Scholar es 20 (1778 citas).

Extracción de información en biomedicina




Fig. 2. Examples of DDIs: effect and mechanism.





Fig. 3. Examples of DDIs: effect and mechanism.




Aplicaciones PLN

Clasificación de textos


Clasificación de Textos

- Clasificar textos en un conjunto de clases o categorías predefinidas.
 - Clasificación binaria (dos clases)
 - Multi-clasificación (tres o más clases).
 - Multi-etiquetado: es posible asignar múltiples clases a un mismo texto.

Clasificación de Textos (binaria)



Clasificación de Textos (binaria)



Iberlef 2023- Autextification

Iberlef 2024-IberAutextification

<https://sites.google.com/view/autextification>, <https://sites.google.com/view/iberautextification>

Clasificación de Textos (multi-clase)




Análisis de
sentimiento



Positive



Neutral



Negative

*"Salgo de la película igual
que he entrado... Se hace
muy larga"*



Negative

Clasificación de Textos (multi-clase)



Clasificación
textos jurídicos


auto

sentencia

recurso

demanda

Clasificación de Textos (multi-clase)



Iberlef 2024-IberAutextification

<https://sites.google.com/view/iberautextification>

Clasificación de Textos (multi-etiquetado)



Detección Mensajes
Odio
IberLef Homo-Mex 2024



Homo-MEX24

Lesbophobia

Gayphobia

Biphobia


Transphobia

Other
LGBT+phobia

Ejemplos:

"Gays y transensuales son una lacra para esta sociedad" -> Gayphobia, Transphobia

"Las lesbianas son todas unas traumatizadas" -> Lesbophobia



Aplicaciones PLN

Asistentes virtuales

Asistentes virtuales



- Basados en LLMs (entrenados con transformers y grandes colecciones de textos).
- Capaces de realizar con éxito muchas de las aplicaciones anteriore:
 - Traducción automática
 - Generación de Resúmenes
 - Búsqueda de Información
 - Preguntas / respuestas
 - Clasificación de textos
 - Extracción de información
 - Generar texto
 - Etc

Gracias

¿preguntas?
isegura@inf.uc3m.es

CREDITS: This presentation template was created by
Slidesgo, and includes icons by **Flaticon** and infographics &
images by **Freepik**

