

**Procesamiento de Lenguaje Natural con
Aprendizaje Profundo,
Máster en Ciencia y Tecnología Informática**

**Tema 4: Word Embeddings
Curso 2025-2026**

Isabel Segura Bedmar



Objetivos

- Conocer el concepto de word embedding
- Conocer principales enfoques para generar word embeddings.
- Conocer las arquitecturas básicas de Word2Vec.
- Entrenar modelos de word-embeddings.
- Utilizar modelos pre-entrenados de word embeddings en la inicialización de redes profundas (tales como CNN o RNN) aplicadas a tareas de PLN.

Introducción

- Redes neuronales operan sobre vectores y matrices.
- Palabras se representan como vectores (embeddings).

Representación One-hot

Cada palabra se representa con un **vector binario** del tamaño del vocabulario (conjunto palabras únicas en la colección de textos).

- Un **1** en la posición de la palabra
- **0** en todas las demás
- La dimensión de los vectores one-hot = tamaño del vocabulario.

Representación One-hot (Ejemplo):

- vocabulario = ["gato", "perro", "pájaro", "pez", "coche"]
 - gato: [1, 0, 0, 0, 0]
 - perro: [0, 1, 0, 0, 0]
 - pájaro: [0, 0, 1, 0, 0]
 - pez: [0, 0, 0, 1, 0]
 - coche: [0, 0, 0, 0, 1]

Modelo One-hot (pros y contras)

Pros: Fácil de implementar y comprender.

Contras:

- Alta dimensionalidad
 - Por ejemplo, el corpus EXIST2021 tiene más de 15.000 palabras distintas.
- Vectores muy dispersos (muchos 0)
- No capturan similitud semántica:
 - $\text{sim}(\text{gato}, \text{perro}) = \text{sim}((1,0,0,0,0), (0,1,0,0,0)) = 0$
 - $\text{sim}(\text{gato}, \text{coche}) = \text{sim}((1,0,0,0,0), (0,0,0,0,1)) = 0$

Alternativa a one-hot: word embeddings

- vectores densos (pocos ceros)
- dimensión: 50, 100, 200, 300 (mucho menor que la dimensión del modelo one-hot).

man →

0.6	-0.2	0.8	0.9	-0.1	-0.9	-0.7
-----	------	-----	-----	------	------	------

source: <https://airbyte.com/data-engineering-resources/sentence-word-embeddings>


Generación aleatoria de word embeddings

- Algunos métodos de inicialización aleatoria son:
 - Inicialización uniforme
 - Inicialización normal
 - xavier
 - he-et-al initialization

✗ No representan significado de las palabras.

✗ No reflejan relaciones sintácticas o semánticas.

¿Es posible aprender word embeddings capaces de capturar información semántica?



¿Qué tienen en común estas oraciones?

- *Mi bebida favorita es el café.*
 - *Mi bebida favorita es el te.*
 - *Mi bebida favorita es el vino.*
 - *Mi bebida favorita es el vino.*
-
- *Madrid es la capital de España*
 - *París es la capital de Francia*
 - *Roma es la capital de Italia*

Hipótesis distribucional (Harris, 1954)

- Palabras que aparecen en contextos similares tienden a tener significados similares.

“You shall know a word by the company it keeps.” — J. R. Firth

¿Qué es un modelo de word embeddings?

- **Vocabulario** (conjunto de palabras) y sus respectivos **embeddings** (vectores).
- Necesita ser **entrenado** con grandes **colecciones de textos** (por ejemplo, Wikipedia).
- Los embeddings codifican el significado de las palabras
- Además, capturan relaciones semánticas con otras palabras del vocabulario.
- Algunos modelos también capturan relaciones morfosintácticas.

Principales modelos para entrenar word embeddings

- [Glove](#) (*matriz de co-ocurrencias*)
- [Word2Vec](#) (*red neuronal aprende word embeddings usando los contextos de las palabras*)
- [fastText](#) (*similar a word2vec que usa n-gramas de caracteres*).

Glove

Construir matriz de coocurrencias entre las palabras.

```
the cat sits on the mat
the dog sits on the sofa
the cat sleeps
the dog sleeps
```

palabra i \ palabra j	cat	dog	sits	sleeps	mat
cat	0	2	2	1	1
dog	2	0	2	1	0
sits	2	2	0	0	1
sleeps	1	1	0	0	0
mat	1	0	1	0	0


Aprenden vectores que cumplan:

$$\text{vector}(w_i) * \text{vector}(w_j) = \log(\text{ocurrencia}(w_i, w_j))$$

Word2Vec (Mikolov et al, 2013)

- **Word2Vec** es una red neuronal con **una única capa oculta**.
- Primer modelo fue entrenado con Google News dataset (100 mil millones de palabras; vocabulario 3 millones; dimension 300).
 - Oraciones tokenizadas (sin signos de puntuación y si números).


Word2Vec: CBOW



el objetivo de la red es predecir una palabra a partir de su contexto

window: size = 5

Word2Vec: skip-gram



objetivo de la red es predecir el contexto más apropiado para una palabra de entrada

CBow versus Skip-gram

- **CBOW**
 - Más rápido
- **skip-gram**
 - apropiado cuando la colección de textos es pequeña.
 - Representa bien incluso palabras raras.

Herramientas, Librerías y repositorios

- Librería [gensim](#)
- [Repositorio](#) con más de 200 modelos.
- Herramienta Spacy

Ventajas Word Embeddings

- Capturan información semántica.
- Entrenar un modelo de word embedding no necesitas un dataset anotado
- Mejoran los resultados en los modelos de deep learning (CNN, RNN, etc) y reducen sus tiempos de entrenamiento.

Limitaciones word embeddings

- Requiere muchos textos (> millón de palabras) y tiempo.
- Embeddings a nivel de palabra.
 - No embeddings para “Joe Biden”, “American Airlines”
 - ‘*bad*’ y ‘*good*’, aunque son antónimos, tiene vectores muy próximos (esto es porque suelen aparecer en contextos similares).
- Un único embedding por palabra. No es capaz de diferenciar palabras polisémicas
 - Ejemplo: mono, puede ser *i) tipo de simio, ii) bonito, gracioso, iii) prenda de vestir.*

OpenCourseWare
Procesamiento de Lenguaje Natural con
Aprendizaje Profundo,

Gracias!!!

<https://github.com/iseaura>